

# Proyecto 1

Bryan Martínez, Adriana Palacios, Brandon Rivera, Javier Benítez, y Pedro Avila

2026-02-13

## Situación Problemática

En los últimos años se ha vuelto común escuchar que el matrimonio y la formación de una familia ya no forman parte de los planes de muchas personas, o que estas decisiones se están postergando a edades más avanzadas. Asimismo, se percibe que las relaciones de pareja tienden a adoptar formas distintas a las tradicionales, ahora vemos a más personas que buscan convivir con una pareja sin matrimonio o bajo compromisos legales.

Sin embargo, estas percepciones sociales no siempre son evidentes o respaldadas con información verídica. En particular, no se conoce con certeza si en Guatemala ha ocurrido una disminución en los matrimonios, un aumento en los divorcios, o cambios significativos en la edad a la que las personas deciden casarse o divorciarse. Tampoco es claro si estos posibles cambios se presentan de manera uniforme en todo el país o si existen departamentos en donde existan diferencias relevantes.

Al tener acceso a datos oficiales por parte de la INE sobre matrimonios y divorcios en Guatemala, surge la necesidad de analizar estos datos para tratar de responder a estas interrogantes. Buscando identificar diferentes patrones a lo largo de la última década y media. Por medio de nuestro análisis seremos capaces de contrastar las percepciones sociales con datos reales, y comprender si realmente ha ocurrido un cambio en la dinámica de los matrimonios y divorcios guatemaltecos.

---

## Problema Científico - ADRIANA ADRIANA ADRIANA

Enuncia el problema científico que se desprende de la situación planteada. Comprende bien cuál es el problema. La idea es que en base a la idea planteada anteriormente, se pueda justificar con algún artículo la presencia de patrones peculiares en el matrimonio/divorcio en los últimos años, o que hablen acerca de las percepciones sociales. Incluir 2 citas como mínimo, citar y colocar referencias en APA-7 al final. La idea es justificar con datos puntuales, por qué la investigación que estamos realizando es relevante.

---

## Objetivos

### Objetivo General

Analizar los datos de matrimonios y divorcios en Guatemala con el fin de identificar patrones demográficos y diferencias entre departamentos, y evaluar si se han producido cambios en la dinámica de estos eventos a lo largo del período analizado.

### Objetivos Específicos

1. Examinar la distribución de los matrimonios y divorcios según los rangos de edad de las personas, con el propósito de identificar posibles variaciones en las edades en las que ocurren estos eventos.
  2. Analizar la distribución de matrimonios y divorcios por departamento, con el fin de detectar la existencia de patrones regionales relevantes.
- 

## Descripción de los Datos

```
# Algunos departamentos vienen escritos diferente, mayúsculas, minúsculas o con/sin tildes.
norm_depto <- function(x) {
  x %>%
    str_trim() %>%
    str_squish() %>%
    stri_trans_general("Latin-ASCII") %>% # quita tildes (Petén -> Peten)
    str_to_lower()
}

matrimonios_depto <- read_csv("matrimonios_depto_mes.csv", show_col_types = FALSE) %>%
  mutate(departamento = norm_depto(departamento))

matrimonios_edad <- read_csv("matrimonios_edad.csv", show_col_types = FALSE)

divorcios_depto <- read_csv("divorcios_depto_mes.csv", show_col_types = FALSE) %>%
  mutate(departamento = norm_depto(departamento))

divorcios_edad <- read_csv("divorcios_edad.csv", show_col_types = FALSE)
```

### Significado y tipo de cada variable

Para el análisis de los datos, se estará trabajando con cuatro datasets con información desde 2009 hasta 2022:

- matrimonios\_depto\_mes: matrimonios registrados en cada mes acorde a cada departamento.
- matrimonios\_edad: matrimonios que ocurrieron en diferentes rangos de edad.
- divorcios\_depto: divorcios almacenados por mes para cada departamento.
- divorcios\_edad: divorcios acontecidos en diferentes rangos de edad.

### Variables Compartidas en Todos los Datasets anio

- Representa el año en que fue registrada la observación.
- La variable es cuantitativa discreta.

### valor

- Número de veces que ocurrió un evento, dependiendo del dataset, este puede representar cantidad de matrimonios o divorcios.
- La variable es cuantitativa discreta.

### **Variables Compartidas en Datasets con Datos Departamentales nivel\_geo**

- Se utiliza para indicar si la observación es de un departamento en específico, o si se tiene registrada a nivel nacional.
- La variable es cualitativa nominal.

### **departamento**

- Es el departamento en donde se registró la observación; este valor puede estar vacío cuando el registro corresponde al total nacional.
- La variable es cualitativa nominal.

### **mes**

- Muestra el número de mes al que corresponden los datos de la observación.
- La variable es cualitativa ordinal; aunque se representa como un número en el dataset, se utiliza para indicar la posición del mes dentro del año y no como una magnitud numérica.

### **Variables Compartidas en Datasets con Datos de Edades edad\_mujer\_grupo**

- Rango de edad al que pertenece la novia/mujer de la observación.
- La variable es cualitativa ordinal.

### **edad\_hombre\_grupo**

- Rango de edad al que pertenece el novio/hombre de la observación.
- La variable es cualitativa ordinal.

## **Cantidad de Variables y Observaciones**

### **Matrimonios por departamento:**

```
dim(matrimonios_depto)
```

```
## [1] 4186     5
```

Se tienen 4186 observaciones y 5 variables.

### **Matrimonios por rangos de edad:**

```
dim(matrimonios_edad)
```

```
## [1] 2191     4
```

Hay 2191 observaciones y 4 variables.

### **Divorcios por departamento:**

```
dim(divorcios_dept)
```

```
## [1] 4186      5
```

Se tienen 4186 observaciones y 5 variables.

#### Divorcios por rangos de edad:

```
dim(divorcios_edad)
```

```
## [1] 1878      4
```

Hay 1878 observaciones y 4 variables.

### Operaciones de Limpieza Realizadas

Al explorar las opciones de descarga de datos disponibles en la plataforma del INE, se observó que gran parte de la información se ofrece en formato .sav, lo cual requiere software de IBM o procesos adicionales para manipularlos. Para facilitar el análisis, se decidió utilizar los libros de Excel disponibles para las estadísticas de matrimonios y divorcios.

Los archivos descargados contenían múltiples hojas y tablas cruzadas que no se encontraban en un formato que se pudiera utilizar directamente para análisis en R. Por esta razón, se realizó un proceso de limpieza. Primero, se seleccionaron únicamente las hojas asociadas a rangos de edad y distribución por departamento en todos los libros de matrimonios y divorcios.

Después, se transformaron las tablas cruzadas a un formato que permitiera el análisis estadístico. La idea era que en cada observación se pudiera identificar sencillamente los datos para un año determinado, logrando reconocer el departamento, rangos de edad de los novios, y la cantidad de un evento (matrimonio o divorcio). Asimismo, se estandarizaron varios datos, pues en varias ocasiones se redactaba de forma distinta, por ejemplo, habían matrimonios o divorcios que ocurrían después de los 65 años, y en algunos documentos aparecía como 65 y mas, y en otros correctamente escrito como 65 y más.

Finalmente, los datos procesados fueron exportados a archivos CSV para facilitar su manipulación y análisis en R.

---

## Análisis Exploratorio

### Exploración de Variables Númericas PEDRITO PEDRITO PEDRITO

(Medidas de tendencia central, distribución y orden. (todas las variables tienen que tener una análisis sobre los resultados, se debe incluir histogramas, boxplots o gráficos de dispersión, uno como mínimo y explicarlo). Para cada una hay que describir su distribución (sacarle su p-value) Si o si piden analizar las variables por técnicas de estadística descriptiva, tener graficos, y sacar la distribucion.)

---

```
print("Matrimonios por departamento")
```

## Medidas de tendencia central

```
## [1] "Matrimonios por departamento"
```

```
summary(matrimonios_depto)
```

```
##      anio      nivel_geo      departamento      mes
##  Min.   :2009  Length:4186   Length:4186   Min.   : 1.00
##  1st Qu.:2012  Class  :character  Class  :character  1st Qu.: 3.75
##  Median :2016  Mode   :character  Mode   :character  Median : 6.50
##  Mean   :2016
##  3rd Qu.:2019
##  Max.   :2022
##                                 NA's   :322
##
##      valor
##  Min.   :    8
##  1st Qu.: 144
##  Median : 235
##  Mean   : 1009
##  3rd Qu.: 437
##  Max.   :87480
##
```

```
print(" ")
```

```
## [1] " "
```

```
print("Matrimonios por edad")
```

```
## [1] "Matrimonios por edad"
```

```
summary(matrimonios_edad)
```

```
##      anio      edad_mujer_grupo      edad_hombre_grupo      valor
##  Min.   :2009  Length:2191   Length:2191   Min.   : 0.0
##  1st Qu.:2012  Class  :character  Class  :character  1st Qu.: 1.0
##  Median :2015  Mode   :character  Mode   :character  Median : 31.0
##  Mean   :2015
##  3rd Qu.:2019
##  Max.   :2022
##                                 NA's   :14859.0
```

```
print(" ")
```

```
## [1] " "
```

```

print("Divorcios por departamento")

## [1] "Divorcios por departamento"

summary(divorcios_depto)

##      anio      nivel_geo      departamento      mes
##  Min.   :2009  Length:4186   Length:4186   Min.   : 1.00
##  1st Qu.:2012  Class  :character  Class  :character  1st Qu.: 3.75
##  Median :2016  Mode   :character  Mode   :character  Median : 6.50
##  Mean   :2016
##  3rd Qu.:2019
##  Max.   :2022
##                NA's   :322

##      valor
##  Min.   :  0.0
##  1st Qu.:  8.0
##  Median : 14.0
##  Mean   : 78.9
##  3rd Qu.: 25.0
##  Max.   :9950.0
##               

print(" ")

## [1] " "

print("Divorcios por edad")

## [1] "Divorcios por edad"

summary(divorcios_edad)

##      anio      edad_mujer_grupo      edad_hombre_grupo      valor
##  Min.   :2009  Length:1878   Length:1878   Min.   : 0.00
##  1st Qu.:2012  Class  :character  Class  :character  1st Qu.: 0.00
##  Median :2015  Mode   :character  Mode   :character  Median : 4.00
##  Mean   :2015
##  3rd Qu.:2019
##  Max.   :2022
##               

print(" ")

## [1] " "

```

Del summary ya podemos sacar unos cuantos datos cuantitativos los cuales no pueden servir probablemente un poco a futuro, como que la media de divorcios por anio y matrimonio por anio tienen un anio de diferencia

```

each_df <- list(
  matrimonios_depto = matrimonios_depto,
  matrimonios_edad = matrimonios_edad,
  divorcios_depto = divorcios_depto,
  divorcios_edad = divorcios_edad
)
plot_histograms_gg <- function(df, df_name, bins = 30) {

  df <- as.data.frame(df)
  numeric_vars <- df[, sapply(df, is.numeric), drop = FALSE]


  for (col_name in names(numeric_vars)) {

    p <- ggplot(df, aes(x = .data[[col_name]])) +
      geom_histogram(bins = bins, fill = "skyblue", color = "white") +
      labs(
        title = paste("Histogram of", col_name, "\nDataset:", df_name),
        x = col_name,
        y = "Frequency"
      ) +
      theme_minimal()

    print(p)
  }
}

for (df_name in names(each_df)) {
  plot_histograms_gg(each_df[[df_name]], df_name)
}


```




### Distribuciones por variables

```
## Warning: Removed 322 rows containing non-finite outside the scale range
## ('stat_bin()').
```


Histogram of mes  
Dataset: matrimonios\_deptos




Histogram of valor  
Dataset: matrimonios\_depto




Histogram of anio  
Dataset: matrimonios\_edad



Histogram of valor  
Dataset: matrimonios\_edad




Histogram of anio  
Dataset: divorcios\_dept




```
## Warning: Removed 322 rows containing non-finite outside the scale range
## ('stat_bin()').
```


Histogram of mes  
Dataset: divorcios\_dept




Histogram of valor  
Dataset: divorcios\_depto



Histogram of anio  
Dataset: divorcios\_edad



Histogram of valor  
Dataset: divorcios\_edad



Como podemos ver de los histogramas, muchas columnas no siguen una distribucion muy clara, como si N cantidad de muestras fueron tomadas siempre por cada mes o anio. Las que si nos importan son como tal la cantidad de divorcios y la cantidad de matrimonios, los cuales a simple vista no parecen que tengan una distribucion normal para nada, si no mas sesgadas a la derecha.

Ademas de eso pareciera al ver el histograma pareciera que tienen una clase de “corelacion” los datos, teniendo un pico extremadamente alto de cantidad de divorcios a cierto punto igual que con los matrimonios, del lado del valor.

```
prueba_lilliefors <- function(df, df_name, alpha = 0.05) {

  df <- as.data.frame(df)
  numeric_vars <- df[, sapply(df, is.numeric), drop = FALSE]

  resultados <- data.frame(
    Dataset = character(),
    Variable = character(),
    P_value = numeric(),
    Normalidad = character(),
    stringsAsFactors = FALSE
  )

  for (col_name in names(numeric_vars)) {
```

```

x <- na.omit(numeric_vars[[col_name]])

test <- lillie.test(x)

decision <- ifelse(test$p.value < alpha,
                     "No tiene normalidad",
                     "No se puede determinar normalidad")

resultados <- rbind(resultados, data.frame(
  Dataset = df_name,
  Variable = col_name,
  P_value = test$p.value,
  Normalidad = decision
))
}

return(resultados)
}

resultados_totales <- data.frame()

for (df_name in names(each_df)) {
  res <- prueba_lilliefors(each_df[[df_name]], df_name)
  resultados_totales <- rbind(resultados_totales, res)
}

print(resultados_totales)

```

## Distribucion normal

```

##           Dataset Variable      P_value      Normalidad
## 1  matrimonios_depto     anio 2.239182e-98 No tiene normalidad
## 2  matrimonios_depto     mes 9.717004e-103 No tiene normalidad
## 3  matrimonios_depto    valor 0.000000e+00 No tiene normalidad
## 4  matrimonios_edad     anio 1.989263e-55 No tiene normalidad
## 5  matrimonios_edad    valor 0.000000e+00 No tiene normalidad
## 6  divorcios_depto     anio 2.239182e-98 No tiene normalidad
## 7  divorcios_depto     mes 9.717004e-103 No tiene normalidad
## 8  divorcios_depto    valor 0.000000e+00 No tiene normalidad
## 9  divorcios_edad     anio 5.925539e-46 No tiene normalidad
## 10 divorcios_edad    valor 0.000000e+00 No tiene normalidad

```

Con el alpha que pusimos podemos percatarnos que ninguno de los datos tiene una distribucion normal, como anteriormente visto facilmente de la forma grafica

## Exploración de Variables Categóricas BENITEZ BENITEZ BENITEZ

Tablas de frecuencia Gráficos de barra para cada una

## Relaciones entre Variables

(este es un poquito peculiar, por como estan los datos, se me ocurre que vean si existe una relación entre la cantidad de casamientos con el rango de edad de la novia o del hombre, y luego, ver si hay una relación entre la cantidad de divorcios y los rangos de edades de los novios/novias).

## Clustering

### Tendencia de Agrupamiento y Número de Clusters

```
# Quedarnos solo con datos departamentales, y segmentados por datos anuales, en vez de mes x año
matrimonios_anual <- matrimonios_deptos %>%
  filter(
    nivel_geo == "departamento",
    is.na(mes)
  ) %>%
  select(anio, departamento, matrimonios = valor)

divorcios_anual <- divorcios_deptos %>%
  filter(
    nivel_geo == "departamento",
    is.na(mes)
  ) %>%
  select(anio, departamento, divorcios = valor)

# Unificar datos anuales de matrimonios y divorcios
matrimonios_divorcios_deptos_anual <- full_join(
  matrimonios_anual,
  divorcios_anual,
  by = c("anio", "departamento")
)

# Variable para analizar el ratio entre divorcios y matrimonios
matrimonios_divorcios_deptos_anual <- matrimonios_divorcios_deptos_anual %>%
  mutate(
    ratio_div_matr = divorcios / matrimonios
  )

matrimonios_divorcios_deptos_anual

## # A tibble: 308 x 5
##       anio departamento  matrimonios  divorcios ratio_div_matr
##   <dbl> <chr>          <dbl>      <dbl>        <dbl>
## 1  2009 alta verapaz     4300      129        0.03
## 2  2009 baja verapaz    1334       66        0.0495
## 3  2009 chimaltenango   3099       56        0.0181
## 4  2009 chiquimula      1766       91        0.0515
## 5  2009 el progreso     786        47        0.0598
## 6  2009 escuintla       2859      160        0.0560
## 7  2009 guatemala      11824     1024        0.0866
## 8  2009 huehuetenango   5276       84        0.0159
## 9  2009 izabal           1276       86        0.0674
```

```
## 10 2009 jalapa      1289      79      0.0613
## # i 298 more rows
```

---